

Министерство науки и высшего образования Российской Федерации
Санкт-Петербургский политехнический университет Петра Великого
Высшая школа программной инженерии

Работа допущена к защите
Директор ВШПИ
_____ П.Д.Дробинцев
«__» _____ 2023 г.

ВЫПУСКНАЯ КВАЛИФИКАЦИОННАЯ РАБОТА

работа бакалавра

ПРИМЕНЕНИЕ НЕЙРОННЫХ СЕТЕЙ ДЛЯ ОЦЕНКИ ТРАФИКА МАГАЗИНА

по направлению подготовки (специальности)

09.03.04 Программная инженерия

Направленность (профиль)

**09.03.04_01 Технология разработки и сопровождения качественного
программного продукта**

Выполнила студентка гр.
3530904/90102

Ли Ицзя

Руководитель
к.т.н., доцент ВШПИ ИКНТ

О. Г. Малеев

Консультант
по нормоконтролю

Е.Г. Локшина

Санкт-Петербург
2023

**САНКТ-ПЕТЕРБУРГСКИЙ ПОЛИТЕХНИЧЕСКИЙ УНИВЕРСИТЕТ
ПЕТРА ВЕЛИКОГО**

**Институт компьютерных наук и технологий
Высшая школа программной инженерии**

УТВЕРЖДАЮ

Директор высшей школы

П.Д. Дробинцев

«06» мая 2023 г.

ЗАДАНИЕ

по выполнению выпускной квалификационной работы
студенту Ли Ицзя, группа 3530904/90102

1. Тема работы: Применение нейронных сетей для оценки трафика магазина.
2. Срок сдачи студентом законченной работы: 22.05.2023
3. Исходные данные по работе: Документация PyTorch
4. Содержание работы (перечень подлежащих разработке вопросов):
 - 1) Обзор литературы
 - 2) Обучение модели для отслеживания людей в нескольких видеопотоках
 - 3) Система оценки трафика магазина основа на нейтронных сетей
 - 4) Анализ полученных результатов
5. Перечень графического материала (с указанием обязательных чертежей):
отсутствует

6. Консультанты по работе:

-

7. Дата выдачи задания: 06.05.2023

Руководитель ВКР

(подпись)

О. Г. Малеев

Задание принял к исполнению 06.05.2023

Студентка

(подпись)

Ли Ицзя

РЕФЕРАТ

На 62 страниц, 27 рисунков, 8 таблицы, 1 приложение

КЛЮЧЕВЫЕ СЛОВА: КОМПЬЮТЕРНОЕ ЗРЕНИЕ, НЕЙРОННЫЕ СЕТИ, ОБНАРУЖЕНИЕ ОБЪЕКТОВ, ОТСЛЕЖИВАНИЕ НЕСКОЛЬКИХ ОБЪЕКТОВ, ПЕРЕИДЕНТИФИКАЦИЯ ПОСЕТИТЕЛЕЙ, YOLO, Улучшенный DeepSORT алгоритм

Выпускная квалификационная работа на тему: «Применение нейронных сетей для оценки трафика магазина».

В данной работе рассматривается реализация алгоритмов нейронных сетей для оценки трафика в магазине. Для решения поставленных задач были использованы методы глубокого обучения и компьютерного зрения.

Задачи, решаемые в ВКР:

1. Для обнаружения посетителей был использован алгоритм YOLOv5
2. Для установления связи между персонажами при работе с несколькими камерами был реализован алгоритм повторного распознавания FastReID.
3. Для отслеживания посетителей был реализован алгоритм DeepSORT на основе.
4. Была разработана система оценки трафика посетителей для супермаркета.
5. Были проведены экспериментальные оценки всех модулей и их сравнение с аналогами.
6. Были проведена экспериментальная оценка системы оценки трафика магазина.

В результате исследования была создана система оценки трафика посетителей для супермаркетов, которая может идентифицировать входящих и выходящих людей с точностью до 95,5% и повторную идентификацию посетителей с точностью до 85,0%. В конце, на других больших открытых наборах данных мы сравнили реализации DeepSORT, FastReID с другими популярными алгоритмами и добились неплохих результатов.

ABSTRACT

62 pages, 27 figures, 8 tables, 1 appendix

KEYWORDS: COMPUTER VISION, NEURAL NETWORKS, OBJECT DETECTION, MULTIPLE OBJECT TRACKING, PEDESTRIAN REIDENTIFICATION, YOLO, IMPROVED DEEPSORT ALGORITHM

Graduation thesis on the topic: "Application of neural networks to assess store traffic."

This paper discusses the implementation of neural network algorithms for evaluating traffic in a store. To solve the tasks, deep learning and computer vision methods were used.

Tasks solved in WRC:

1. YOLOv5 algorithm was used to detect pedestrians
2. To establish communication between characters when working with several cameras, the FastReID re-recognition algorithm was implemented.
3. To track pedestrians, the DeepSORT algorithm was implemented based on.
4. A system for assessing visitor traffic for the supermarket was developed.
5. Experimental evaluations of all modules and their comparison with analogues were carried out.
6. An experimental evaluation of the store's traffic evaluation system was carried out.

As a result of the study, a visitor traffic estimation system for supermarkets was created, which can identify incoming and outgoing people with an accuracy of up to 95.5%, and re-identify pedestrians with an accuracy of up to 85.0%. In the end, on other large open datasets, we compared DeepSORT, FastReID implementations with other popular algorithms and achieved good results.

СОДЕРЖАНИЕ

СПИСОК ИЛЛЮСТРАЦИЙ.....	8
СПИСОК ТАБЛИЦ	10
ВЕДЕНИЕ	11
ГЛАВА 1. ОБЗОР ЛИТЕРАТУРЫ	13
1.1 Обнаружение посетителей	13
1.2 Отслеживание посетителей в виде последовательности	16
1.2.1 Алгоритм трекинга множества объектов DeepSORT.....	17
1.2.2 Набор данных MOT-16.....	18
1.2.3 Метрики оценки эффективности модели	19
1.3 Повторная идентификация посетителей.....	19
1.3.1 Алгоритм FastReID	22
1.3.2 Набор данных MSMT17	24
1.3.3 Метрики оценки эффективности модели	25
ГЛАВА 2. ОБУЧЕНИЕ И УСТРАИВАНИЕ МОДЕЛЕЙ	27
2.1 Обучение модели FastReID	27
2.1.1 Принципы обучения	27
2.1.2 Построить модель	27
2.1.3 Функции потерь	28
2.1.4 Ходы обучения	30
2.1.5 Результаты обучения	31
2.2 Устраивание модели DeepSORT	32
ГЛАВА 3. СИСТЕМА ОЦЕНКИ ТРАФИКА МАГАЗИНА	34
3.1 Цели разработки системы	34
3.2 Описание системы	34

3.2.1 Общая архитектура системы	34
3.2.2 Модуль обнаружения посетителей	35
3.2.3 Модуль отслеживания посетителей.....	35
3.2.4 Модуль подсчета и распознавания посетителей	36
3.2.5 Модуль хранения	39
3.2.6 Среда разработки	39
3.3 Демонстрация системы.....	39
3.3.1 Общая принципиальная схема системы	39
3.3.2 Функционалы системы.....	40
ГЛАВА 4. АНАЛИЗ ПОЛУЧЕННЫХ РЕЗУЛЬТАТОВ	44
4.1 Экспериментальная оценка модели FastReID.....	44
4.2 Экспериментальная оценка улучшенной модели DeepSORT	45
4.3 Экспериментальная оценка системы оценки трафика магазина.....	47
4.3.1 Результат подсчета входов и выходов посетителей.....	47
4.3.2 Результат межкамерной Ре-идентификации посетителей.....	48
ЗАКЛЮЧЕНИЕ	52
СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ	54
ПРИЛОЖЕНИЕ 1	58

СПИСОК ИЛЛЮСТРАЦИЙ

Рис. 1.1 Визуализация обнаруживаемых объектов.....	13
Рис. 1.2 Архитектура YOLOv5	15
Рис. 1.3 Принципиальная схема алгоритма MOT	16
Рис. 1.4 Принципиальная схема DeepSORT	17
Рис. 1.5 Обзор набора данных MOT16. Вверху: тренировочные последовательности; внизу: тестовые последовательности	19
Рис. 1.6 Пример повторной идентификации	20
Рис. 1.7 Сочетание ReID с сопровождением	22
Рис. 1.8 Общая схема тренировки и рассуждения модели FastReID	23
Рис. 2.1 Тренировки модели FastReID	31
Рис. 3.1 Общая архитектура системы оценки трафика магазина.....	35
Рис. 3.2 Иллюстрация двухлинейного метода	37
Рис. 3.3 Краткая иллюстрация Ре-идентификации.....	38
Рис. 3.4 Блок-схема системы оценки трафика магазина	40
Рис. 3.5 Иллюстрация отслеживания человека №881	40
Рис. 3.6 Иллюстрация отслеживания посетителя sus-43 под 3 камерами...	41
Рис. 3.7 Информация о времени прохождения, ID персонала и общего количества входящих и выходящих.....	42
Рис. 3.8 Записи времени входа и выхода покупателей	42
Рис. 3.9 Вырезанные изображения покупателей из 1-ой камерой.....	42
Рис. 3.10 Вырезанные изображения покупателей из 2-ой камерой.....	43
Рис. 3.11 Вырезанные изображения покупателей из 2-ой камерой.....	43
Рис. 4.1 План этажа супермаркета и расположение трех камер	47
Рис. 4.2 Скриншоты 20 посетителей.....	49
Рис. 4.3 Срыв подсчета человека из-за перекрытия людей между собой ..	49
Рис. 4.4 Человек, из внешнего вида которого unsuccessfully восстановить ID	50
Рис. 4.5 Правильный дескриптор входящего должен быть такой	50

Рис.4.6 Срыв подсчета человека из-за перекрытия людей между собой...	50
Рис. 4.7 Записи времени	51

СПИСОК ТАБЛИЦ

Таблица. 2.1 Результаты обучения на наборе данных MSMT17.....	31
Таблица. 2.2 Сравнение FastReID с другими алгоритмами на наборе MSMT17	32
Таблица. 3.1 Аппаратные среды	39
Таблица. 3.2 Программные среды	39
Таблица.4.1 Результаты экспериментов на наборе данных Market1501 и DukeMTMC	44
Таблица. 4.2 Результаты экспериментов на наборе данных MOT-16	45
Таблица.4.3 Результаты экспериментов на наборе данных MOT-17	46
Таблица.4.4 Результат подсчета входов и выходов посетителей.....	47

ВЕДЕНИЕ

С развитием розничной торговли и усилением конкуренции, многие торговые центры осознали важность данных о потоках посетителей для принятия эффективных бизнес-решений. Изучение трафика покупателей является ключевым элементом для научного управления торговыми центрами во всех аспектах и повышения комфорта торговой среды.

Традиционный метод искусственного подсчета, который представляет собой непрерывное визуальное подсчитывание посетителей на входе и выходе, не требует больших капиталовложений, однако его использование ограничено трудовыми и материальными ресурсами и подвержено ошибкам. С появлением механического сенсорного оборудования, инфракрасного сенсорного оборудования и оборудования для камер наблюдения, методы подсчета посетителей прошли две стадии: статистику физического прикосновения и статистику инфракрасного излучения. Однако, данные методы имеют ряд очевидных недостатков, таких как высокие требования к установке оборудования, низкую скорость и точность подсчета.

Для эффективного управления и поддержки принятия решений для супермаркетов необходим более точный, автоматизированный и эффективный метод. В данной работе рассматривается алгоритм мониторинга и расчета пассажиропотока магазина с использованием метода нейронных сетей.

Основная цель данной работы заключается в разработке метода, который сочетает в себе алгоритмы обнаружения, отслеживания и повторной идентификации посетителей, чтобы получить времени посещения магазина. Были использованы зрелые технологии глубокого обучения, такие как алгоритм YOLOv5, алгоритм отслеживания DeepSORT и алгоритм повторной идентификации посетителей FastReID.

Для достижения цели данной работы нужно выполнить следующие задачи:

1. Реализовать алгоритм YOLOv5

2. Реализовать алгоритм повторного распознавания FastReID.
3. Реализовать алгоритм DeepSORT на основе YOLOv5 и FastReID.
4. Разработать система оценки трафика посетителей для супермаркета.
5. Провести экспериментальные оценки всех модулей и их сравнение с аналогами.
6. Провести экспериментальную оценку системы оценки трафика магазина.

Таким образом, разработанная система может эффективно улучшить управление трафиком внутри супермаркета, повысить качество обслуживания клиентов и увеличить прибыльность бизнеса.

ГЛАВА 1. ОБЗОР ЛИТЕРАТУРЫ

1.1 Обнаружение посетителей

Суть обнаружения посетителей заключается в обнаружении объектов. Обнаружение объектов лежит в основе задач многоцелевого сопровождения, основная цель которого — отметить объект, подлежащий обнаружению, прямоугольной рамкой (bounding box) из статической картинке каждого кадра и получить конкретное местоположение объекта на картинке. Если при обнаружении объекта происходит пропущенное обнаружение, объект не будет отслеживаться позже, поэтому обнаружение объекта играет очень важную роль в задачах отслеживания нескольких объектов.




Рис. 1.1 Визуализация обнаруживания объектов

Появление сверточных нейронных сетей значительно повысило эффективность методов обнаружения объектов. Такие алгоритмы можно условно разделить на следующие две категории. Одна из них представляет собой двухэтапный алгоритм обнаружения, который сначала выбирает области-кандидаты на изображении, а затем выполняет задачи классификации этих областей. Этот тип алгоритма характеризуется высокой точностью, но медленной скоростью. Например, R-CNN, предложенная Россом [8], сначала предварительно определяет области, которые должны быть обнаружены на изображении, с помощью операции выборочного поиска, а затем извлекает признаки этих областей с помощью сверточной нейронной сети и, в конце,

классифицирует их. Хотя алгоритм R-CNN значительно повышает точность обнаружения объектов, он имеет проблему вычислительной избыточности. Алгоритм sppnet, предложенный He [9], устраняет влияние повторяющегося масштабирования изображений R-CNN путем добавления слоя объединения пространственных пирамид. Кроме того, Гиршик [3] предложили алгоритм Fast R-CNN, который дополнительно оптимизировал алгоритмы R-CNN и sppnet, добавив слой объединения регионов. Рен [4] предложили алгоритм Faster R-CNN, который заменил выборочный поиск сетью предложений регионов и обучил сеть от начала до конца, что значительно повысило скорость детектора. Другой представляет собой одноэтапный алгоритм обнаружения, который выполняет регрессию для вывода положения и категории объекта обнаружения при создании области-кандидата. Репрезентативным алгоритмом является алгоритм серии YOLO [5].

Серия алгоритмов YOLO была впервые предложена Редмоном в 2016. Он отказался от двухэтапной парадигмы обнаружения «обнаружение предложения + проверка» и напрямую предсказал вероятность категории и положение каждой сетки, разделив изображение на несколько сеток., информация.

Из приведенного выше введения мы делаем вывод, что традиционные подходы к обнаружению объектов обычно требуют ручного проектирования функций и классификаторов, которые плохо работают в сложных сценах и требуют большого опыта и времени для настройки параметров. Напротив, технология обнаружения объектов на основе глубокого обучения использует глубокие нейронные сети для автоматического изучения функций и классификаторов, что обеспечивает более высокую точность и надежность и подходит для различных сложных сцен. Мы выбрали YOLOv5 в качестве детектора объектов для исследовательского проекта. По словам авторов статьи [6], на момент своего появления, модель YOLO явилась самой передовой в области обнаружения объектов на изображениях. Она была протестирована на широко используемых наборах данных, таких как PASCAL VOC и COCO, и

продемонстрировала высокую точность, превосходящую альтернативные подходы Faster R-CNN и SSD, при этом затрачивая меньше времени на обработку.

Исходя из вышеперечисленных преимуществ, YOLOv5 больше подходит для наших сценариев использования.

YOLOv5 был предложен автором Glenn Jocher. Существует четыре моделей, а именно YOLOv5s, YOLOv5m, YOLOv5l и YOLOv5x. Среди них YOLOv5s имеет наименьшее количество сверточных слоев, самую быструю скорость обнаружения и самую низкую точность обнаружения, для остальных трех моделей количество сверточных слоев расположено в порядке возрастания. По мере увеличения сложности модели обнаружение Скорость постепенно снижается, а точность обнаружения постепенно увеличивается.

Структура YOLOv5 состоит из четырех частей: Input, Backbones, Neck и Prediction, как показано на рисунке.




Рис. 1.2 Архитектура YOLOv5

Сторона ввода включает в себя улучшение Mosaic, динамическую опорную рамку, адаптивную обработку изображений и т. Д.; Магистралы включают в себя кросс-этапную локальную сеть CSP, пространственный пирамидный пул SPPF, первый помогает сократить объем вычислений, а второй повышает точность

обнаружения; Neck использует FPN+ Структура PAN, понижающая дискретизация улучшает семантическую информацию, повышающая дискретизация улучшает информацию о местоположении; Прогноз является конечным результатом обнаружения.

Чтобы добиться более высокой скорости, мы выбираем предварительно обученную модель YOLOv5s, выпущенную веб-сайтом с открытым исходным кодом YOLOv5 [29].

1.2 Отслеживание посетителей в виде последовательности

Задача Отслеживание (Трекинг) объектов в видеопотоке заключается в сопоставлении детекция объекта на последовательности кадров видеопотока треку объекта. Задача трекинга множества объектов (Multi-Object Tracking, MOT) заключается в трекинге нескольких различных объектов [1]. В частности, алгоритм трекинга множества объектов(далее – алгоритм MOT) решает проблему обнаружения объектов, которые мы хотим отслеживать, в каждом кадре видео, получения позиции на кадре и присвоения идентификатора каждому объекту. В процедуру трекинга идентификатор каждого объекта должен оставаться неизменным.



Рис. 1.3 Принципиальная схема алгоритма MOT

Как показано на рисунке, после ввода последовательности кадров, собранных камерой, в алгоритм MOT выводятся результаты отслеживания нескольких объектов в кадре, включая местоположение каждого объекта на изображении и соответствующую идентификационную информацию.

По сравнению с отслеживанием одного объекта задача MOT должна не только сталкиваться с такими проблемами, как изменение освещения, окклюзия и

размытие движения, но также решать такие проблемы, как неопределенное количество объектов и прерывание траекторий объектов во время процесса отслеживания. С непрерывным ростом исследований многоцелевого отслеживания в последние годы, связанные с ними методы появляются бесконечно. Далее рассматривается популярный алгоритм MOT – DeepSORT

1.2.1 Алгоритм трекинга множества объектов DeepSORT

DeepSORT [7] является усовершенствованием алгоритма отслеживания SORT. Основная цель DeepSORT — генерировать непрерывные траектории движения множества персонажей в видеопотоке, а общий рабочий процесс показан на рисунке ниже. Чтобы уменьшить количество переключателей идентификатора цели отслеживания (переключение идентификатора, ID switch), DeepSORT вводит функции внешнего вида и каскадное сопоставление. Алгоритм DeepSORT принимает координаты кадра обнаружения и достоверность результатов обнаружения сети обнаружения объектов в качестве входных данных, предсказывает положение людей в следующем кадре с помощью алгоритма фильтра Калмана, выполняет каскадное сопоставление, а затем использует венгерский алгоритм для ассоциации данных. В конце, фильтр Калмана обновлен.




Рис. 1.4 Принципиальная схема DeepSORT

DeepSORT вычисляет сходство, используя информацию о движении и внешнем виде цели (человека). Для информации о движении расстояние

Махаланобиса используется для оценки корреляции между прогнозируемым объектом и обнаруженным объектом. Выражение расстояния Махаланобиса:

$$d^{(1)}(i, j) = (d_j - y_i)^T S_i^{-1} (d_j - y_i) \quad (1.1)$$

Где d_j – позиция bounding box j , y_i – позиция, предсказанное фильтром Калмана, S_i – ковариационная матрица обнаруженных и предсказанных позиций.

Когда объект перекрыт в течение длительного времени или угол обзора колеблется, необходимо ввести информацию о внешнем виде и использовать косинусное расстояние для решения проблемы переключения идентичности, вызванного окклюзией.

Выражение косинусного расстояния:

$$d^{(2)}(i, j) = \text{Min} \{ 1 - r_j^T r_k^{(i)} \mid r_k^{(i)} \in R_i \} \quad (1.2)$$

Где r_j — собственный вектор bounding box d_j ; $r_k^{(i)}$ — набор собственных векторов, соответствующих последним 100 кадрам трека i ; R_i — набор векторов признаков внешнего вида.

Чтобы в полной мере использовать два вида информации, для суммирования используется линейно-взвешенный метод:

$$c_{i,j} = \lambda d^{(1)}(i, j) + (1 - \lambda) d^{(2)}(i, j) \quad (1.3)$$

В формуле: λ является гиперпараметром тогда и только тогда, когда значение измерения $c_{i,j}$ Существует между $d^{(1)}(i, j)$ И $d^{(2)}(i, j)$, только в этом случае он считается относящимся к цели.

Стоит заметить, что, поскольку алгоритм фильтра Калмана основан на линейном равномерном движении, алгоритм DeepSORT может предсказывать состояние цели только в линейной среде и может быть не в состоянии хорошо предсказать, когда траектория человека нелинейна.

1.2.2 Набор данных MOT-16

Этот набор данных является общим набором данных, используемым для оценки производительности алгоритмов MOT. Существуют различные сцены, в

том числе 14 видеопоследовательностей, а 7 видеопоследовательностей помечены подробно с идентификаторами людей и позициями кадров, которые используются для обучать алгоритмов MOT, еще 7 видеофрагментов служат тестовой выборкой.



Рис. 1.5 Обзор набора данных MOT16. Вверху: тренировочные последовательности; внизу: тестовые последовательности

1.2.3 Метрики оценки эффективности модели

Критерии оценки, использованные в эксперименте: MOTA - Accuracy отслеживания объектов, MOTP - Precision отслеживания объектов, MT - mostly tracked, ML - mostly lost, IDs - — количество ложной смены. MOTA и MOTP вычисляются следующим образом:

$$MOTA = 1 - \frac{\sum_t (m_t + n_t + s_t)}{\sum_t g_t} \quad (1.4)$$

$$MOTP = \frac{\sum_{i,t} d_i^t}{\sum_t c_t} \quad (1.5)$$

Где t представляет t -й кадр, m_t представляет количество пропущенных объектов обнаружения в t -кадре; n_t представляет количество ложных объектов обнаружения в t -кадре; s_t представляет количество переключений идентичности в t -кадре; g_t представляет общее количество объектов в кадре t ; расстояние между прогнозируемой позицией объекта кадра i и реальной позицией; c_t представляет количество успешно сопоставленных объектов в кадре t .

1.3 Повторная идентификация посетителей

Повторная идентификация множества людей (Person Re-identification, ReID) также известная как Ре-идентификация человека или междукamerное сопровождение — это новая технология, появившаяся в области интеллектуального анализа видео в последние годы. Ре-идентификация

множества людей может быть определена как задача присвоения одного и того же имени или индекса всем образам одного и того же человека, получаемым с пространственно-разнесенных камер, области видимости которых не пересекаются друг с другом, на основе выделения и анализа признаков его изображений [2].

При выполнении задачи повторной идентификации людей мы обычно разделяем все изображения людей на две группы: набор запросов (Query) и набор галерей (Gallery). Набор запросов (Query): коллекция изображений, которые мы хотим использовать для поиска подобных изображений в наборе галерей. Набор галерей (Gallery): коллекция всех доступных изображений для поиска. А запрос (probe или query image), это одно изображение или группа связанных изображений для поиска.

Цель повторной идентификации людей заключается в том, чтобы найти все изображения людей в наборе галереи, которые похожи или совпадают с изображениями в наборе запроса, и могут быть точно аутентифицированы или идентифицированы.



Рис. 1.6 Пример повторной идентификации

Для выполнения задачи ReID, одной из основных проблем является выбор дескриптора, описывающего человека [10]. Для решения указанных задач требуется выявить отличительные признаки объектов, в том числе людей, на изображениях [2].

Традиционный метод заключается в ручном извлечении признаков изображения, например, цвета, HOG (гистограмма направленных градиентов)

[11], SIFT (масштабно-инвариантное преобразование функций) [12], LOMO (локальный максимальный возникновение). Затем используется XQDA (кросс-видовой квадратичный дискриминантный анализ) [13] или KISSME (простое и прямолинейное изучение метрики) [14] для изучения лучшего измерения сходства. Однако традиционные методы ручного описания особенностей имеют ограниченные возможности и трудно применяются к задачам с большим объемом данных в сложных сценах. Кроме того, при обработке больших объемов данных традиционные методы обучения измерений также становятся очень сложными.

В последние годы глубокое обучение, представленное сверточными нейронными сетями, достигло больших успехов в области компьютерного зрения, победив традиционные методы в многих задачах и даже в какой-то мере превзойдя уровень человека [15-16]. В случае повторной идентификации людей методы на основе глубокого обучения могут автоматически извлекать сложные описания признаков и использовать простые евклидовы расстояния для измерения сходства, что дает хорошие результаты. Другими словами, глубокое обучение может реализовать задачу повторной идентификации людей полностью, что делает задачу более простой. В настоящее время методы повторной идентификации людей на основе глубокого обучения значительно превосходят традиционные методы по производительности. Эти преимущества делают глубокое обучение популярным в области повторной идентификации людей.

Повторная идентификация людей обычно используется в сочетании с отслеживанием людей. На рис. 1.7 показана общая схема этого сочетания.




Рис. 1.7 Сочетание ReID с сопровождением

Имеются разнообразные модели повторной идентификации. Среди них мы выбрали алгоритм FastReID [17], основанный на метрическом обучении в качестве метода повторной идентификации людей исследовательского проекта. Были проведены экспериментальная оценка и его сравнение с другими алгоритмами. Результаты показали, что она сыграла очень хорошую роль в нашем проекте. Ниже мы представим его подробно.

1.3.1 Алгоритм FastReID

Благодаря построению нейронной сети повторной идентификации WRN, DeepSORT способен эффективно решать проблему перекрытия. WRN состоит главным образом из остаточных блоков, имеет много параметров и требует больших вычислительных затрат. Чтобы улучшить скорость и способность идентификации повторной идентификации сети, мы вводим модель повторной идентификации человека FastReID взамен WRN. Это позволяет снизить вычислительную сложность, увеличить экспрессивность и достичь более быстрой скорости и лучшего эффекта идентификации. FastReID в целом состоит из четырех частей: предварительная обработка изображения, основная сеть,

интеграция функций и головные сети. Общая архитектура показана на следующей рисунке:




Рис. 1.8 Общая схема тренировки и рассуждения модели FastReID

При обучении модели FastReID сначала используйте модуль предварительной обработки данных для улучшения и предварительной обработки изображения, затем используйте модуль магистральной сети для извлечения функций реснета и повысьте стабильность модели с помощью модуля нормализации пакетов экземпляров (IBN). Затем используйте модуль интеграции функций, чтобы объединить эти функции в глобальный вектор функций и использовать функции потерь (включая кросс-энтропийную потерю, тройную потерю, потерю дуги и круговую потерю) для обучения классификатора. Классификатор состоит из трех частей: головка BN, линейная головка и головка редукции, а также слои Conv, ReLU, Dropout и Reduction. После обучения модель можно использовать для вывода.

При рассуждении модели FastReID изображение запроса сначала соответствующим образом предварительно обрабатывается, и 512-мерный глобальный вектор признаков генерируется через магистральную сеть, интеграцию признаков и классификатор. Затем модуль метрики расстояния используется для сравнения сходства изображения запроса с изображениями

базы данных и возврата набора наиболее похожих результатов. Наконец, используйте модуль постобработки для обработки результатов, включая такие методы, как k-обратное кодирование и расширение запроса, чтобы повысить точность поиска. Производительность модели обычно оценивается стандартными метриками (такими как CMC, mAP, ROC и minp и т. д.). Для лучшего просмотра результатов поиска FastReID также предоставляет инструменты визуализации для представления результатов поиска.

1.3.2 Набор данных MSMT17

Для выполнения процедуры обучения нейронной сети возникла необходимость найти такой набор данных, который бы покрывал различные условия съёмки и содержал большое количество кадров с людьми.

На конференции CVPR2018 был предложен новый крупномасштабный набор данных MSMT17 [18], который ближе к реальной сцене, а именно Multi-Scene Multi-Time, охватывающий несколько сцен и несколько периодов времени. Набор данных MSMT17 использует сеть из 15 камер видеонаблюдения в кампусе, включая 12 наружных камер и 3 внутренние камеры. Для сбора необработанного видео наблюдения было выбрано 4 дня в месяц с разными погодными условиями. Каждый день собирается 3 часа видео, охватывающих три временных периода: утро, полдень и день. Таким образом, общая продолжительность необработанного видео составляет 180 часов.

Три комментатора-человека потратили два месяца на просмотр обнаруженных ограничивающих прямоугольников и пометку людей. В конце, получается 126 441 ограничительная рамка 4 101 людей.

Набор данных случайным образом делится в соотношении обучение-тестирование 1:3, а не поровну, как другие наборы данных. Целью этого является поощрение эффективных стратегий обучения, поскольку маркировка данных очень дорога в реальных приложениях.

В конце, обучающий набор содержит 1041 людей с 32621 ограничивающей рамкой, а тестовый набор содержит 3060 людей с 93820 ограничивающими

рамками. Для тестового набора 11659 ограничивающих рамок выбираются случайным образом в качестве запроса, а остальные 82161 ограничивающие рамки используются в качестве галереи.

Показатели теста - кривая СМС и mAP. Для каждого запроса может быть несколько положительных совпадений.

1.3.3 Метрики оценки эффективности модели

В исследованиях повторной идентификации людей для оценки эффективности модели в основном используются два показателя оценки: точность k-ой совпадения Rank-k и средняя средняя точность (Mean Average Precision, mAP).

Точность k-ой совпадения (Ранг-k)

Ранг-k конкретно относится к вероятности нахождения одного и того же изображения человека на k изображениях, наиболее похожих на изображение, которое необходимо получить *probe* в галерее G. Вычисление Ранг-k выглядит следующим образом:

$$Rank(k) = \frac{1}{N} \sum_{i=1}^N \begin{cases} 1, & r_i \leq k \\ 0, & r_i > k \end{cases} \quad (1.6)$$

Где $r_i (i = 1, 2, \dots, N)$ указывает индекс в отсортированном списке изображения с правильным совпадением идентификатора; N указывает количество изображений в галерее.

Вообще говоря, Ранг-1 является наиболее важным показателем для оценки эффективности модели повторной идентификации человека, который может быть выражен как вероятность того, что первое изображение в полученном отсортированном списке является тем же человеком, что и изображение, которое нужно получить. В реальных ситуациях, помимо использования ранга-1, другие часто используемые ранг-k включают ранг-5, ранг-10, ранг-20 и т. д.

Средняя средняя точность (mAP)

Изображение *probe* обычно можно найти несколько совпадающих изображений с одинаковым идентификатором в библиотеке изображений-

кандидатов G , и трудно оценить влияние труднодоступных образцов на производительность модели, используя только оценки Rank- k . Следовательно, для более полной оценки эффективности модели повторной идентификации человека к индексу оценки модели повторной идентификации человека добавляется средняя точность. Средняя точность — это индекс, который может оценить результаты ранжирования всех положительных образцов. Только когда все изображения извлеченного человека ранжируются вверху в библиотеке кандидатов, индекс mAP будет высоким, поэтому он может более полно отражать людей. При расчете mAP сначала вычисляется средняя точность (Average Precision, AP), соответствующая каждому извлекаемому изображению *probe*, которая используется для измерения точности распознавания модели на одном образце запроса. Процесс расчета показан в формуле:

$$AP(q) = \frac{\sum_{k \in \{k_1, k_2, \dots, k_S\}} \frac{k_r}{k}}{S} \quad (1.7)$$

Где S указывает количество положительных образцов, соответствующих полученному изображению *probe* в библиотеке кандидатов G , $\{k_1, k_2, \dots, k_S\}$ — позиции индекса S положительных образцов в результатах сортировки, а k_r указывает количество положительных образцов в первых k результатах. В конце, после вычисления средней точности всех изображений людей в библиотеке Q , содержащей m изображений, можно использовать среднее значение значений AP всех выборок для получения mAP. Процесс расчета показан в формуле:

$$mAP = \frac{\sum_{q_i \in Q} AP(q_i)}{m} \quad (1.8)$$

ГЛАВА 2. ОБУЧЕНИЕ И УСТРАИВАНИЕ МОДЕЛЕЙ

2.1 Обучение модели FastReID

2.1.1 Принципы обучения

Принципы обучения модели FastReID заключается в следующем:

1.Предварительная обработка данных: сначала изображения в наборе данных предварительно обрабатываются с вероятностью 0,5 обрезки, масштабирования, симметрии и улучшения данных, чтобы повысить устойчивость модели к изображениям людей в разных позах и условиях освещения.

2.Извлечение признаков: FastReID использует обученную сверточную нейронную сеть серии ResNet50 в качестве экстрактора признаков для извлечения 512-мерного вектора признаков из входного изображения. В то же время FastReID также вводит некоторые новые методы извлечения признаков, такие как выравнивание с учетом масштаба (Scale-Aware Alignment, SAA [27]) и случайное стирание, для дальнейшего улучшения способности выражения признаков.

3.Метричное обучение: вектор признаков сопоставляется с низкоразмерным пространством посредством метрического обучения, а функции потерь Triplet Loss и Cross Entropy Loss используются для оптимизации модели, так что образцы с одной и той же идентичностью находятся ближе в пространстве признаков. , и разные идентичности образцы находятся дальше друг от друга в пространстве признаков.

4.Оптимизация модели: использовать оптимизатор Adam для оптимизации параметров модели, чтобы повысить эффективность обучения и точность модели.

2.1.2 Построить модель

Чтобы ускорить сходимость моделей и повысить производительность модели, мы используем ResNet50, модель сверточной нейронной сети, предварительно обученную на наборе данных ImageNet. ImageNet — это широко используемый

набор данных для классификации изображений, который содержит 1,4 миллиона изображений в более чем 1000 категориях. Модель ResNet50 использует глубокую остаточную сетевую структуру, которая может эффективно справляться с крупномасштабными задачами классификации изображений. После завершения обучения веса модифицированной модели можно использовать в других задачах компьютерного зрения для повышения производительности и эффективности задачи, например, в нашей повторной идентификации посетителей.

Размерность выходных признаков предварительно обученной модели ResNet50 составляет 2048. Мы продолжаем вставлять средний слой пула и линейный классификатор после магистральной сети. Выходная размерность линейного классификатора равна N. N представляет собой идентификационный номер обучающих данных.

2.1.3 Функции потери

Наша модель Ре-идентификация дает два выхода: вектор признаков f^{gen} и предсказанные логиты p . Вектор признаков f^{gen} используются для расчета триплетных потерь, а логиты p используются для расчета энтропии перекрестных потерь.

Cross Entropy Loss (Энтропии перекрестных потерь)

Cross Entropy Loss — это широко используемая функция потери классификации, которая обычно используется для обучения глубоких нейронных сетей задачам классификации изображений. В частности, для входной выборки x и ее истинной метки y формула расчета перекрестной энтропийной потери выглядит следующим образом:

$$\text{Cross Entropy Loss} = - \sum_{i=1}^C y_i \log(\hat{y}_i) \quad (2.1)$$

Где C — количество категорий, y_i представляет вероятность i -й категории (то есть истинной метки), а \hat{y}_i представляет вероятность того, что модель предсказывает, что x принадлежит i -й категории.

Цель Cross Entropy Loss — минимизировать разрыв между предсказанием и реальной меткой, чтобы модель могла более точно предсказывать категорию, к которой относится каждая выборка (каждый человек в обучающей выборке рассматривается как отдельная категория).

Triplet Loss (Триплетная потеря)

Triplet Loss - это одна из функций потерь, которая широко используется в области распознавания лиц. Ее основное назначение - приблизить векторы встраивания изображений одного человека и отдалить векторы встраивания изображений разных людей.

Данная функция принимает на вход триплет $\{a, p, n\}$, который состоит из трех изображений, включая пару положительных образцов $\{a, p\}$ и пару отрицательных образцов $\{a, n\}$. Анкер a - это фиксированное изображение, а положительный образец p и отрицательный образец n - другие два изображения. Для данного триплета формула расчета Triplet Loss имеет вид:

$$\text{Triplet Loss} = \max(0, d(a, p) - d(a, n) + m) \quad (2.2)$$

где $d(a, p)$ - евклидово расстояние между анкером и положительным значением, $d(a, n)$ - евклидово расстояние между анкером и отрицательным значением, а m - отступ, который является предустановленным гиперпараметром A , обычно положительным числом.

Таким образом, если расстояние между текущим якорем и плюсом минус расстояние между якорем и минусом плюс маржа меньше или равно 0, это означает, что текущий вектор встраивания достаточно хорош и не нуждается в оптимизации. В противном случае необходимо обновить параметры модели для лучшего встраивания векторов.

Triplet Loss обычно используется в сочетании с Batch Hard Triplet Mining, где для обучения в каждой партии выбирается самый сложный триплет. Данный метод заключается в выборе изображений людей, очень похожих на якорь, но разных категорий, в качестве отрицательных образцов, и выборе изображений

людей, которые сильно отличаются от якоря, но принадлежат к той же категории, что и положительные образцы, чтобы улучшить производительность модели.

2.1.4 Ходы обучения

На этапе обучения включает следующие шаги:

Шаг 1: Мы используем ResNet50 (веса инициализированы из предварительно обученной модели ImageNet), а затем изменяем ее полносвязный слой до N. N является идентификационным номером обучающих данных.

Шаг 2: Случайным образом выбираем P идентификаторов и собираем K изображений для каждого идентификатора, размер последней партии $B = P * K$. В данной статье мы устанавливаем $P = 16$, $K = 4$.

Шаг 3: Размер каждого изображения изменяется на 256×128 , 10 пикселей заполнены значениями 0, затем изображение повторно обрезается до размера 256×128 с использованием случайного кадрирования.

Шаг 4: Каждое изображение случайным образом отражается по горизонтали с вероятностью 0,5.

Шаг 5: Каждое изображение декодируется как 32-битное необработанное значение пикселя с плавающей запятой в $[0,1]$, затем каналы RGB нормализуются путем вычитания 0,485, 0,456, 0,406 и деления на 0,229, 0,224, 0,225.

Шаг 6: Модель выводит вектор признаков f^{gen} для предсказания логитов p.

Шаг 7: Вектор признаков ReID f^{gen} используются для вычисления триплетных потерь(triplet loss), логиты p используются для вычисления энтропии перекрестных потерь. Значение m триплетных потерь устанавливается равным 0,3.

Шаг 8: Метод Адама используется для оптимизации модели. Начальная скорость обучения установлена на $3.5 * 10^{-4}$ и уменьшается на $3.5 * 10^{-4}$ в 40-ом эпохе и $3.5 * 10^{-4}$ в 70-ом эпохе соответственно. Всего 120 эпох обучения.




Рис. 2.1 Тренировки модели FastReID

2.1.5 Результаты обучения

Мы используем 1/3 данных в MSMT17 в качестве образцов для обучения модели FastReID, а затем используем оставшиеся 2/3 данных в качестве проверочного набора для проверки возможностей модели. Результаты экспериментальной оценки при тестировании приведены в таблице.

Таблица. 2.1 Результаты обучения на наборе данных MSMT17

Dataset	Rank-1↑	Rank-5↑	Rank-10↑	mAP↑
MSMT17	84.19	90.95	95.10	62.89

По результатам экспериментальной оценки видно, что модель FastReID добилась хороших результатов на наборе данных MSMT17. Она достиг 84,19% точности на 1-м ранге, 90,95% и 95,10% на 5-м и 10-м рангах соответственно. При этом средняя точность (mAP) также достигла 62,89%, что означает, что производительность модели стабильна.

В целом эти результаты показывают, что модель FastReID хорошо работает с набором данных MSMT17.

Были проведены сравнение с другими алгоритмами на том же наборе:

Таблица. 2.2 Сравнение FastReID с другими алгоритмами на наборе MSMT17

Methods	Rank-1↑	MAP↑
Ianet (IVPR'19) [19]	75.7	45.8
Auto-ReID (ICCV'19) [20]	78.2	52.5
Osnet (ICCV'19) [21]	78.7	52.9
Abdnet (ICCV'19) [22]	82.3	60.8
Circle Loss (CVPR'20) [23]	76.9	52.1
Ours	84.19	62.89

Через сравнение мы знаем, что mAP нашей модели намного выше, чем у других моделей, выпущенных в то же время, и rank-1 является лучшим.

2.2 Устраивание модели DeepSORT

Шаг 1: Используем DeepSORT в качестве сети отслеживания, чтобы отслеживать каждого человека и сопоставлять его с предыдущими траекториями.

Шаг 2: Используем YOLOv5s в качестве части обнаружения DeepSORT для обнаружения людей в каждом кадре изображения и вывода кадра обнаружения.

Шаг 3: Используем FastReID в качестве экстрактора признаков для извлечения признаков внешнего вида людей, чтобы DeepSORT мог различать разных людей.

Шаг 4: Определим гиперпараметры модели. Параметры модели улучшенного алгоритма DeepSORT следующие:

```
DEEPSORT:
REID_CKPT: "./fast-ReID/checkpoint/model-final.pth"
MAX_DIST: 0.2
MIN_CONFIDENCE: 0.3
NMS_MAX_OVERLAP: 0.5
MAX_IOU_DISTANCE: 0.7
MAX_AGE: 140
N_INIT: 3
NN_BUDGET: 100
```

Мы используем общедоступный набор данных MOT-16 для тестирования модели отслеживания множества объектов (DeepSORT после улучшения модуля

повторной идентификации людей). Чтобы лучше подчеркнуть производительность алгоритма в этой статье, для сравнения были проведены два разных эксперимента на наборе данных MOT-16 и MOT-17. Результаты и анализ показаны в гл. 4.

ГЛАВА 3. СИСТЕМА ОЦЕНКИ ТРАФИКА МАГАЗИНА

3.1 Цели разработки системы

Оценки трафика посетителей на основе видеонаблюдения является основой для сбора бизнес-информации и выполнения задач интеллектуального управления, а также важным функциональным компонентом современного интеллектуального видеонаблюдения. В этом проекте будут использоваться передовые технологии компьютерного зрения и глубокого обучения, такие как YOLOv5, DeepSORT и FastReID. В частности, система будет получать видеопотоки в магазине из несколько камеров, использовать YOLOv5 для автоматического обнаружения, появляющихся на видео, затем использовать DeepSORT для отслеживания покупателя и, в конце, использовать FastReID для идентификации и анализа поведение покупателя, чтобы реализовать автоматическую статистику и анализ посещаемости магазина.

Благодаря исследованиям и практике этого проекта он может помочь продавцам более точно понять привычки и предпочтения поведения посетителей, сформулировать более научные и эффективные стратегии продаж, а также повысить прибыльность и рыночную конкурентоспособность магазинов. В то же время система также может предоставлять продавцам функции мониторинга и прогнозирования потоков посетителей в режиме реального времени, помогая продавцам еще больше оптимизировать управление операциями, повышать уровень обслуживания и удобство работы пользователей.

3.2 Описание системы

3.2.1 Общая архитектура системы

На основе FastReID и DeepSORT разрабатывается система оценки трафика покупателей, ориентированная на небольшие магазины. Система состоит из четырех модулей: 1)модуль обнаружения посетителей, 2)модуль отслеживания

посетителей, 3)модуль подсчета и распознавания посетителей и 4)модуль хранения. Общая архитектура системы показана на рисунке.

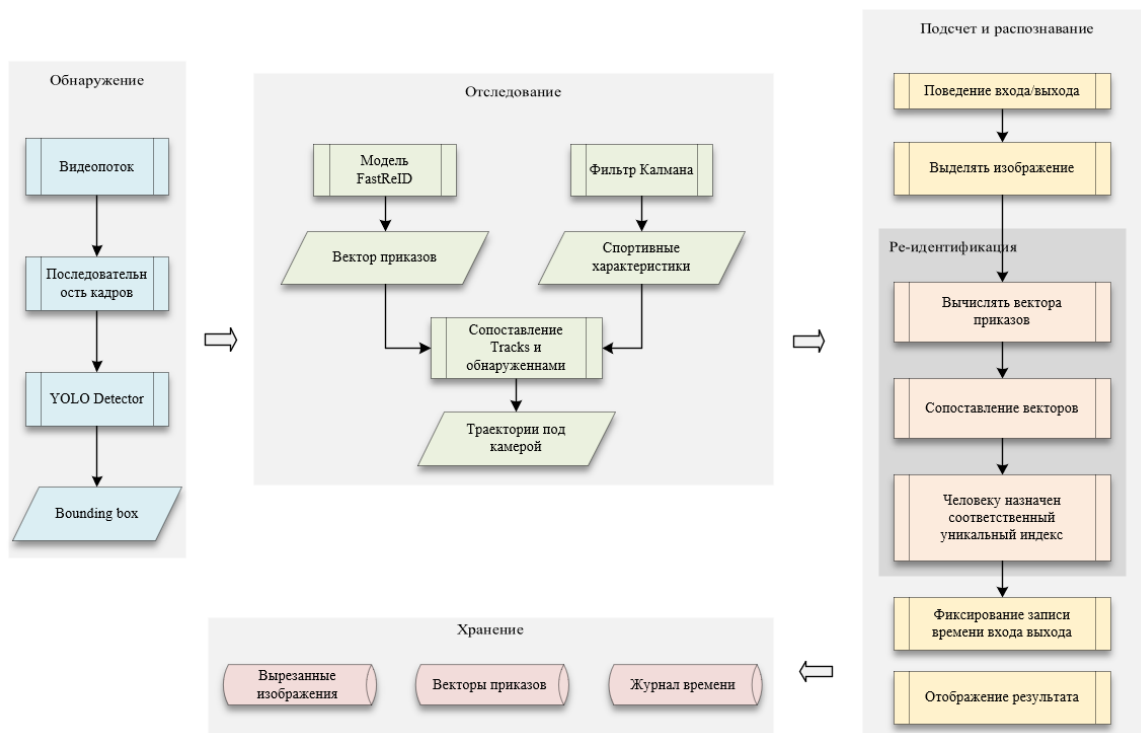


Рис. 3.1 Общая архитектура системы ценки трафика магазина

3.2.2 Модуль обнаружения посетителей

На вход модуля обнаружения посетителей подается видеопоток с одной камеры, в процессе реализации в данной работе используется алгоритм обнаружения объектов YOLO. YOLO используется для выделения посетителей в каждом кадре видео. Посетители помечаются прямоугольным кадром. Конкретное положение посетителя в возвращается картинка, определение которой приведено в формуле:

$$b = [x, y, w, h] \quad (3.1)$$

Где (x, y) — пиксельные координаты верхнего левого угла кадра обнаружения, а (w, h) — ширина и высота кадра обнаружения.

3.2.3 Модуль отслеживания посетителей

Модуль отслеживания посетителей использует модель DeepSORT, и его входными данными является текущий кадр и координаты всех людей. Цель этой модули состоит в том, чтобы связать обнаруженные посетители в текущем кадре

с существующими траекториями в предыдущих кадрах, впоследствии создавать новые траектории. После получения кадра обнаружения и координатов, предоставленных модулем обнаружения посетителей, сначала использовать модуль FastReID и алгоритм Калмана, чтобы извлечь признаки внешнего вида и признаки движения посетителей в текущем кадре, а затем вычислить матрицу расстояний между ними. В конце, использовать венгерский алгоритм для сопоставления. В качестве выходных данных получены траектории всех посетителей в текущем кадре.

3.2.4 Модуль подсчета и распознавания посетителей

Этот модуль использует траектории движения всех людей, которые находятся под одной камерой. Его цель состоит в том, чтобы учитывать количество людей, входящих и выходящих из магазина, а также проводить ре-идентификацию для тех, кто передвигался вдоль указанных направлений. Это позволит собирать статистические данные о времени и количестве уникальных вхождений каждого человека на территорию магазина, которая покрывается несколькими камерами видеонаблюдения. В результате работы модуля будет произведен обрезанный снимок изображения каждого человека, на основе которого будут сформированы векторы признаков, а также зафиксированы записи в журнале времени входа/выхода.

3.2.4.1 Подсчет посетителей

После рассмотрения реалистичных требований к задаче в этом исследовании используется «метод двух линий» для осуществить подсчёт людей. Конкретный принцип двухлинейного метода заключается в следующем:



Рис. 3.2 Иллюстрация двухлинейного метода

В магазине устанавливается стационарная камера и получается видеопоток наблюдения. Причем в видеопотоке отмечаются две счетные линии, которые записываются как А и В. На основе траектории движения тела на пересечении траектории и линии указывается направления (вход/выход) проходящих людей.

В качестве примера предположим, что магазин находится слева от линии В, как показано в рисунке. Видно, что траектория входа посетителя будет сначала соприкасаться с линией А, а затем с контактом с В, это называется поведением входа. И наоборот, траектория ухода посетителя должна сначала коснуться линии В, а затем линии А, это называется поведением выхода. Нам нужно только записать, касается ли траектория посетителя сначала линии А или линии В, а затем мы уже можем определить, входит ли посетитель в магазин или выходит из него. Перебирая весь видеопоток, мы можем получить точное количество людей, входящих и выходящих.

3.2.4.2 Ре-идентификация

Краткая иллюстрация Ре-идентификации представлена на рисунке.

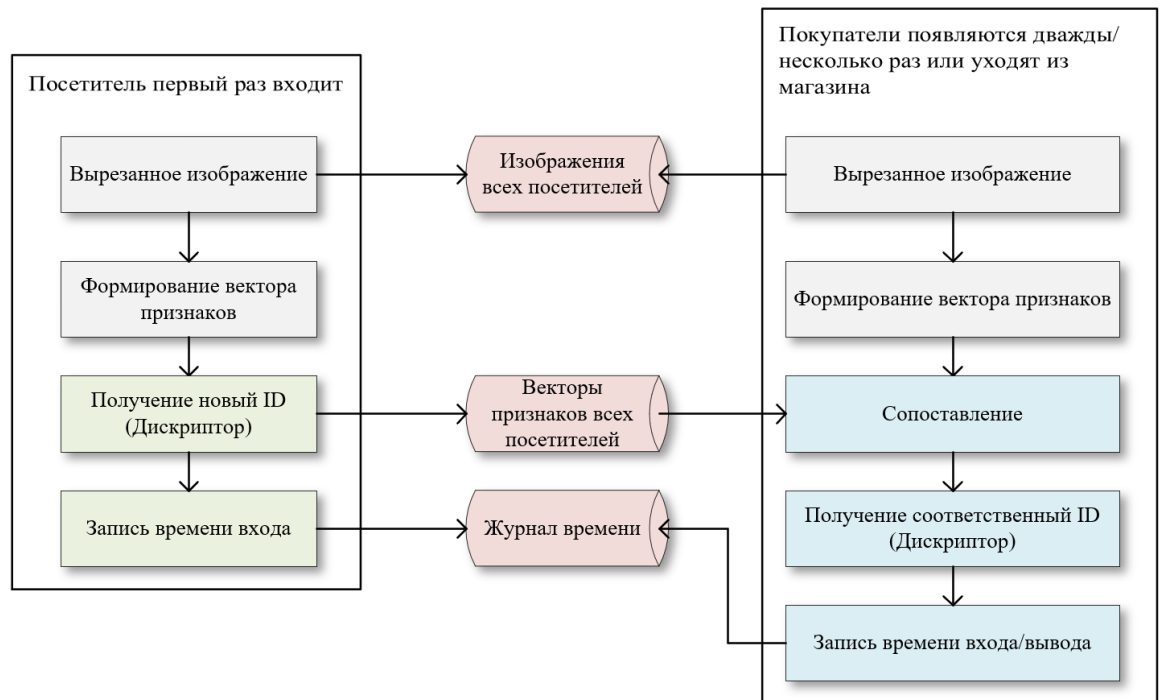


Рис. 3.3 Краткая иллюстрация Ре-идентификации

Для описания человека при ре-идентификации дескриптор может быть представлен как:

$$P_{ID} = (p^{ID}, f^{gen}) \quad (3.2)$$

Где p^{ID} – идентификатор (метка) человека; f^{gen} - вектор признаков для изображения человека. Создается таблица, содержащая изображения всех посетителей и их дескрипторы, которая называется галереей.

Когда происходит поведение входа/выхода, будет вычисление вектора признаков f^{gen} , который используется для определения расстояния d между данной персоной и дескрипторами изображений в галерее. Расстояния d затем используются для ранжирования таблицы от d_{min} до d_{max} . Если значение расстояния d превышает пороговое значение, то считается, что запрос не соответствует ни одному дескриптору в галерее, и соответствующий дескриптор добавляется в конец таблицы с новым уникальным идентификатором человека. После исключения всех неподходящих кандидатов из таблицы, для повторной идентификации выбирается человек с наиболее схожим вектором признаков

f^{gen} , который находится вверху списка ранжированной таблицы. Это человек, который будет принят за результат повторной идентификации. После этого будет возвращаться уникальный идентификатор человека.

Таким образом, все посетители получают уникальные идентификаторы, и на этой основе фиксируются времени входы/выхода. В качестве выходных данных создается журнал, где записаны ID камер, идентификатор человека и времени появления.

3.2.5 Модуль хранения

Модуль хранения отвечает за сохранение времени входа/выхода, изображений и векторы признаков, полученных из предыдущего модуля. В конце, создается окончательный журнал, где записаны ID человека, в каких отделах он появился, время появления и изображение человека. Журнал сохраняется на диске для последующего статистического анализа.

3.2.6 Среда разработки

Аппаратные среды, использованные для разработки, показаны в Таблице 1:

Таблица. 3.1 Аппаратные среды

Предмет	Технические характеристики	Комментарий
Чип	AMD Ryzen 5 5600H with Radeon Graphics 3.30 GHZ	-
Памяти	16.0 GB	ПО использует до 2.1 GB
Камер	1080P	720P минимум
ОС	Windows 10 Professional	-

Программные среды, использованные в разработке, показаны в Таблице 2:

Таблица. 3.2 Программные среды

Предмет	Версия	Комментарий
Python	3.8.16	Данная или выше
Pycharm	2022.1.2 (Educational Edition)	Данная или выше
Opencv	4.5.3	Данная или выше
Pytorch	1.13.0	Данная или выше

3.3 Демонстрация системы

3.3.1 Общая принципиальная схема системы

Блок схема системы показана ниже на рисунке:




Рис. 3.4 Блок схема системы оценки трафика магазина

3.3.2 Функционалы сисетмы

3.3.2.1 Отследование посетителей под одной камерой

На следующей рисунке выбираются 300-й, 330-й, 360-й, 390-й кадры из видеопотоке, полученная из камеры №3, чтобы иллюстрировать отслеживание человека №881.



Рис. 3.5 Иллюстрация отслеживание человека №881

Видно, что отслеживание человека у № 881 хорошее в пределах 90 кадров, потому что идентификатор у него всегда сохраняется без переключения. Даже если перекрывание между людьми возникает в 390-ом кадре, идентификатор посетителя остается №881, когда перекрывания исчезает. Это роль ассоциации признаков внешнего вида, предоставляемая FastReID. Кроме того, другие посетителя, отличные от 881, такие как 803, 819, 869, также хорошо отслеживаются.

Результаты испытаний доказывают, что система может непрерывно отслеживать нескольких посетителей под одной камерой.

3.3.2.2 Отслеживание посетителей под несколькими камерами

На трех нижеприведенных иллюстрациях показаны результаты отслеживания посетителя sus-43, проходящего через три камеры в хронологическом порядке.



Рис. 3.6 Иллюстрация отслеживания посетителя sus-43 под 3 камерами

Из результатов видно, что при первом появлении посетителя в зоне наблюдения камеры 1 система выдает ей идентификатор sus-43, который является глобально уникальным. Когда посетитель sus-43 исчез из поля зрения камеры 1 и вошел под камерой 2, система извлекла черты его внешности через FastReID для сопоставления, узнала идентификационную информацию посетителя sus-43 и восстановила отслеживание. Отображается информация в правом нижнем углу ограничительной рамки человека. Аналогично, когда она вышла из камеры 2 и вошла под камерой 3, система также успешно восстановила ее отслеживание в зоне наблюдения камеры 3.

На кадрах существуют желтая и зеленая виртуальные линии, они не реалины. Эти линии используются только для подсчета количества людей.

Когда посетители проходят через линии, в левом нижнем углу экрана печатаются информации времени прохождения, ID персонала и общего количества входящих и выходящих.



Рис. 3.7 Информации времени прохождения, ID персонала и общего количества входящих и выходящих

3.3.2.3 Записи времени входа и выхода покупателей

Мы используем структуру данных в Python для записи входных и выходных записей всех посетителей за определенный период времени. Распечатаем его, как показано ниже на рисунке.

PERSON-ID	CAMERA-ID	TIME	CAMERA-ID	TIME	CAMERA-ID	TIME
cus-1	cam-1	2023-05-10 03: 31: 27	cam-2	2023-05-10 03: 37: 59	cam-3	2023-05-10 03: 46: 04
cus-5	cam-1	2023-05-10 03: 31: 37	cam-2	2023-05-10 03: 50: 03	cam-3	
cus-35	cam-1	2023-05-10 03: 32: 03	cam-2	2023-05-10 03: 38: 10	cam-3	2023-05-10 03: 46: 19
cus-71	cam-1	2023-05-10 03: 32: 11	cam-2	2023-05-10 03: 38: 15	cam-3	2023-05-10 03: 46: 23
cus-82	cam-1	2023-05-10 03: 32: 37	cam-2	2023-05-10 03: 38: 26	cam-3	2023-05-10 03: 46: 35
cus-94	cam-1	2023-05-10 03: 32: 48	cam-2	2023-05-10 03: 38: 32	cam-3	2023-05-10 03: 46: 42
cus-101	cam-1	2023-05-10 03: 32: 53	cam-2	2023-05-10 03: 41: 28	cam-3	
cus-103	cam-1	2023-05-10 03: 32: 53	cam-2	2023-05-10 03: 41: 39	cam-3	2023-05-10 03: 50: 03
cus-108	cam-1	2023-05-10 03: 33: 00	cam-2	2023-05-10 03: 41: 02	cam-3	2023-05-10 03: 49: 20
cus-120	cam-1	2023-05-10 03: 33: 10	cam-2	2023-05-10 03: 42: 06	cam-3	2023-05-10 03: 50: 23
cus-134	cam-1	2023-05-10 03: 33: 14	cam-2	2023-05-10 03: 42: 30	cam-3	
cus-147	cam-1	2023-05-10 03: 33: 21	cam-2	2023-05-10 03: 42: 57	cam-3	2023-05-10 03: 51: 18
cus-203	cam-1	2023-05-10 03: 34: 15	cam-2	2023-05-10 03: 42: 59	cam-3	2023-05-10 03: 51: 16
cus-253	cam-1	2023-05-10 03: 35: 21	cam-2		cam-3	
cus-248	cam-1	2023-05-10 03: 35: 24	cam-2		cam-3	
cus-257	cam-1	2023-05-10 03: 35: 28	cam-2		cam-3	
cus-306	cam-1	2023-05-10 03: 36: 17	cam-2		cam-3	
cus-314	cam-1	2023-05-10 03: 36: 30	cam-2		cam-3	
cus-331	cam-1	2023-05-10 03: 36: 53	cam-2		cam-3	
cus-335	cam-1	2023-05-10 03: 36: 56	cam-2		cam-3	

Рис. 3.8 Записи времени входа и выхода покупателей

3.3.2.4 Вырезанные изображения покупателей

Вырезанные изображения покупателей из 1-ой камерой (частично):



Рис. 3.9 Вырезанные изображения покупателей из 1-ой камерой

Вырезанные изображения покупателей из 2-ой камерой (частично):




Рис. 3.10 Вырезанные изображения покупателей из 2-ой камерой

Вырезанные изображения покупателей из 3-ой камерой (частично):



Рис. 3.11 Вырезанные изображения покупателей из 2-ой камерой

ГЛАВА 4. АНАЛИЗ ПОЛУЧЕННЫХ РЕЗУЛЬТАТОВ

4.1 Экспериментальная оценка модели FastReID

После завершения обучения модели мы протестировали нашу модель на наборе данных Market1501 [26] и DukeMTMC [30], даже и сравнили с другими моделями ReID:

Таблица.4.1 Результаты экспериментов на наборе данных Market1501 и DukeMTMC

Methods	Market1501		DukeMTMC	
	Rank-1	mAP	Rank-1	mAP
IANet (IVPR'19) [19]	94.4	83.1	87.1	73.4
Auto-ReID (ICCV'19) [20]	94.5	85.1	-	-
OSNet (ICCV'19) [21]	94.8	84.9	88.6	73.5
ABDNet (ICCV'19) [22]	95.6	88.3	89.0	78.6
Circle Loss (CVPR'20) [23]	96.1	87.4	89.0	79.6
ours	95.7	88.4	90.1	81.3

Согласно приведенным выше данным, мы видим, что модель FastReID хорошо работает как с наборами данных Market1501, так и с наборами данных DukeMTMC. Его Rank-1 в наборе данных Market1501 составляет 95,7%, mAP — 88,4%, а его Rank-1 в наборе данных DukeMTMC — 90.1%, mAP — 81,3%.

По сравнению с другими моделями FastReID показала очень хорошую производительность. В наборе данных Market1501 Rank-1 FastReID и mAP превзошли такие IANet, Auto-ReID, ABDNet и OSNet; В наборе данных DukeMTMC его Rank-1 и mAP превзошли все другие алгоритмы. Это показывает, что FastReID превосходит других конкурентов по точности первого питания идентификации и средней точности. Она обладает высокой надежностью и способностью к задаче повторной идентификации.

В заключение, основываясь на этих оценочных метриках, мы можем считать FastReID эффективной моделью повторной идентификации личности, которую предполагается применять в практических сценариях.

4.2 Экспериментальная оценка улучшенной модели DeepSORT

Мы протестируем все видеопоследовательности в наборе данных MOT16, в которых идентификаторы людей и положения границ отмечены вручную, всего 7 видеопотоков. Это: MOT16-02, MOT16-04, MOT16-05, MOT16-09, MOT16-10, MOT16-11, MOT16-13.

Результаты представлены в таблице.

Таблица. 4.2 Результаты экспериментов на наборе данных MOT-16

Algorithm	MOTA ↑	MOTP ↑	MT / % ↑	ML / % ↓	Ids / % ↓	FPS / Hz ↑
SORT [24]	59.8	79.6	25.4	22.7	1423	8.6
Original DeepSORT [18]	61.4	79.1	32.8	18.2	781	6.4
JDE [25]	64.4	-	35.4	20	1544	18.5
Ours	66.2	80.8	35.3	17.6	760	9.8

По результатам видно, что после улучшения алгоритма DeepSORT все показатели улучшаются. MOTA увеличилась на 4,8%, MOTP увеличилась на 1,7%, MT увеличилось на 2,5%, ML сократилось на 0,6%, а общее количество целевых переключателей идентификации (IDs) сократилось в 21 раз. На основании экспериментальной оценки можно утверждать, что внедрение FastReID и YOLOv5 действительно повышает точность отслеживания и возможность сохранения идентификатора посетителя алгоритма DeepSORT.

По сравнению с другими моделями наша модель имеет комплексные преимущества: MOTA и MOTP самые высокие, а MT практически равно JDE и делят первое место. ML и IDs являются самыми низкими.

Кроме того, замечено, что производительность в реальном времени немного хуже, чем у алгоритма JDE, потому что JDE является одноэтапным алгоритмом отслеживания, а отслеживание в реальном времени относительно высоко, но переключение идентификаторов относительно частые, что обусловлено взаимным перекрытием мишеней. В розничной среде часто бывают сцены с большим количеством плотных посетителей, поэтому наш алгоритм является подходящим выбором в это время.

Мы даже провели сравнительный эксперимент на более сложном новом наборе данных MOT17.

Мы протестировали алгоритм многоцелевого отслеживания на четырех подмножествах набора данных MOT17 и сравнили результаты с результатами в конкурсе MOT Challenge. В сравнении использовались 4 видеопоследовательностей, для которых опубликованы результаты [28].

Измерение проводилось с использованием 5 показателей точности – MOTA, IDF1, MT, ML и IDs.

Результат показан на таблице:

Таблица.4.3 Результаты экспериментов на наборе данных MOT-17

Tracker	MOTA / % ↑	IDF1 / % ↑	MT/% ↑	ML/% ↓	IDs ↓
MFI	60.1	58.8	26.0	29.7	2065
ISE_MOT17R	60.1	56.4	28.5	28.1	2556
SLA	59.7	63.4	24.0	31.1	1647
LPC_MOT	59.0	66.8	29.9	33.9	1122
MPNTrack	58.8	61.7	28.8	33.5	1185
ours	60.4	64.9	30.2	27.9	1192

По таблице видно, что наш многоцелевой алгоритм отслеживания работает очень хорошо по всем показателям. Наш трекер имеет оценку MOTA 60.4, что немного выше, чем у других трекеров; Имеет более высокий показатель IDF1, чем большинство других трекеров, что означает, что он лучше избегает ложных

срабатываний; Имеет показатель МТ 30.2%, что выше, чем у других трекеров; Имеет показатель МL 27.9%, что ниже, чем у других трекеров; IDs нашего трекера (1192) выше, чем у некоторых конкурентов (LPC_MOT и MPNTrack), но отклонение не велико.

На основании экспериментальной оценки можно утверждать, что данный улучшенный алгоритм является более универсальным, чем другими.

4.3 Экспериментальная оценка системы оценки трафика магазина

Для проверки работоспособности различных функций в этой системе тест проведен в крупном супермаркете ОКЕЙ. Мы развернули 3 фиксированные камеры по траектории посетителей, входящих в супермаркет, для получения видео. План этажа супермаркета и расположение трех камер показаны на рисунке выше. Продолжительность видеозаписи около 2 минут.

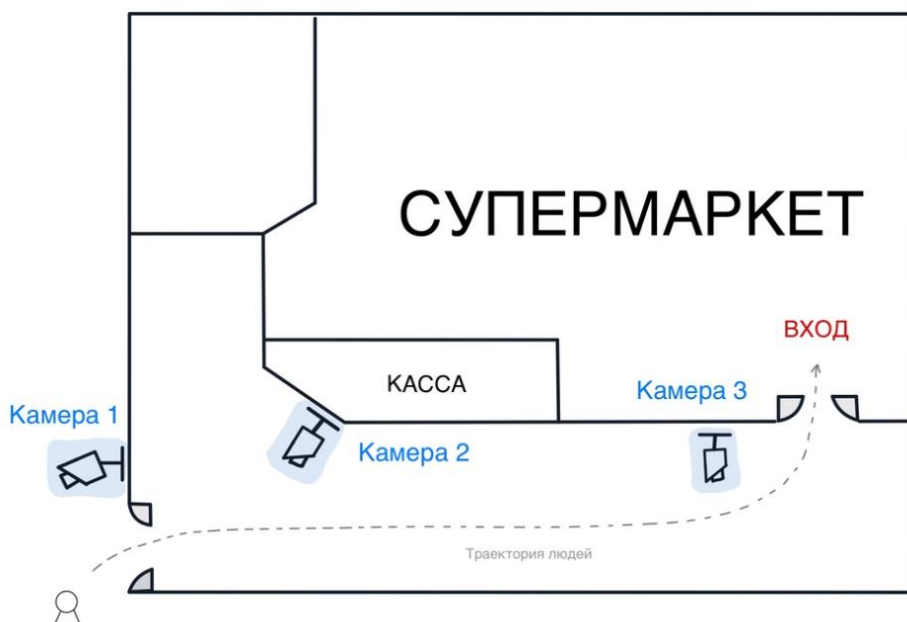


Рис. 4.1 План этажа супермаркета и расположение трех камер

4.3.1 Результат подсчета входов и выходов посетителей

Результат подсчета входов и выходов посетителей представлены в таблице ниже:

Таблица.4.4 Результат подсчета входов и выходов посетителей

Камера	Реальные значения		Статистические значения		Точность
	Направление	Количество посетителей	Направление	Количество посетителей	
Cam1	Вход	30	Вход	30	100.00%
	Выход	16	Выход	15	93.75%
	Всего	46	Всего	45	97.83%
Cam2	Вход	30	Вход	28	93.33%
	Выход	23	Выход	20	86.96%
	Всего	53	Всего	48	90.57%
Cam3	Вход	28	Вход	27	96.43%
	Выход	25	Выход	25	100.00%
	Всего	53	Всего	52	98.11%
Всего				Вход	96.59%
				Выход	93.57%
				Всего	95.50%

Эти данные получают путем подсчета потока людей двухстрочным методом, включающим реальные и статистические значения количеств посетителей под трех камер. Видно, что каждая камера имеет разную точность подсчета в направлении входа и выхода, но в целом средние точности являются 96.59% (вход), 93.57% (выход) и 95.50% (вход и выход всего).

Заметили, что точность камеры 2 в направлении выхода относительно низкая, есть 86.96%. Это из-за того, что на определенном интервале времени появилось скопление народа. Из-за перекрытия людей, было 3 пропущенных инспекционных персонала, которые понизил среднюю точность. Точность камеры 1 и камеры 3 относительно высока, выше 97%. Это связано с тем, что в этих двух сценариях почти нет больших толп людей, входящих и выходящих из магазина.

В целом, несмотря на то, что еще есть возможности для повышения точности, общая производительность относительно стабильна и точна, что может помочь руководителям объектов лучше понимать поток людей.

4.3.2 Результат межкамерной Ре-идентификации посетителей

В этом тесте мы под три камерами отследовали 20 человек. Эти 20 человек идут с камеры 1, через камеру 2, к камере 3, то есть они фактически имели полную траекторию, пересекающую камеру.

В cam1 20 человек, формировалось 20 скриншотов посетителей. То есть на данный момент в таблице 20 дискрипторов.




Рис. 4.2 Скриншотов 20 посетителей

Под камерой-2 прошло 20 человек, а скриншотов сформировалось всего 19. Было два посетителя, идущих параллельно и один из них скрыт, показано ниже на рисунке.



Рис. 4.3 Срыв подсчета человека из-за перекрытия людей между собой

Из-за этого, происходило одно пропущенное обнаружение. Среди 19 изображений, 18 человек получили правильную идентификаторы с помощью повторной идентификации. 1 человек не смог получить соответствующий идентификатор из-за того низкой схожести с исходном дискриптом. Поэтому он был назначен новый ID. По полученной статистике вычисляется точность повторной идентификации по камерой №2: $18/20=90,0\%$.



Рис. 4.4 Человек, из внешнего вида которого unsuccessfully восстановить ID



Рис. 4.5 Правильный дескриптор входящего должна быть такой

Под камерой-3 прошли 20 человек, сформировалось 19 скриншотов. Было три посетителя, идущих параллельно и один из них скрыт, показано ниже на рисунке.



Рис.4.6 Срыв подсчета человека из-за перекрытия людей между собой

Из-за этого, происходило одно пропущенное обнаружение. Среди 19 изображений, 19 человек получили правильные идентификаторы с помощью повторной идентификации. По полученной статистике вычисляется точность повторной идентификации по камерой №3: $19/20=95,0\%$.

Формировалась экспериментальная таблица, где представлялись изображения всех отслеживаемых посетителей под 3 камерами. Таблица положила в приложении 1.

Записали времени, когда они входят в магазин (виртуальное время в экспериментальной среде):

```

1  ], 'customer-2': {'cam-1': '2023-05-15 13: 26: 36', 'cam-2': '2023-05-15 13: 33: 20', 'cam-3': '2023-05-15 13: 40: 24'
2  }, 'customer-5': {'cam-1': '2023-05-15 13: 26: 45', 'cam-2': '2023-05-15 13: 33: 43', 'cam-3': '2023-05-15 13: 42: 01'
3  }, 'customer-8': {'cam-1': '2023-05-15 13: 26: 55', 'cam-2': '2023-05-15 13: 33: 31', 'cam-3': '2023-05-15 13: 40: 38'
4  }, 'customer-21': {'cam-1': '2023-05-15 13: 26: 59', 'cam-2': '2023-05-15 13: 36: 31', 'cam-3': '2023-05-15 13: 45: 21'
5  }, 'customer-25': {'cam-1': '2023-05-15 13: 27: 00', 'cam-2': '2023-05-15 13: 33: 37', 'cam-3': '2023-05-15 13: 40: 38'
6  }, 'customer-34': {'cam-1': '2023-05-15 13: 27: 11', 'cam-2': '2023-05-15 13: 33: 47', 'cam-3': '2023-05-15 13: 40: 55'
7  }, 'customer-43': {'cam-1': '2023-05-15 13: 27: 25', 'cam-2': '2023-05-15 13: 33: 56', 'cam-3': '2023-05-15 13: 41: 01'
8  }, 'customer-58': {'cam-1': '2023-05-15 13: 27: 28', 'cam-2': '2023-05-15 13: 34: 10', 'cam-3': '2023-05-15 13: 44: 10'
9  }, 'customer-61': {'cam-1': '2023-05-15 13: 27: 30', 'cam-2': '2023-05-15 13: 34: 10', 'cam-3': '2023-05-15 13: 41: 49'
10 }, 'customer-77': {'cam-1': '2023-05-15 13: 27: 39', 'cam-2': '2023-05-15 13: 34: 10', 'cam-3': '2023-05-15 13: 41: 28'
11 }, 'customer-123': {'cam-1': '2023-05-15 13: 28: 39', 'cam-2': '2023-05-15 13: 39: 09', 'cam-3': '2023-05-15 13: 42: 44'
12 }, 'customer-183': {'cam-1': '2023-05-15 13: 30: 16', 'cam-2': '2023-05-15 13: 37: 35', 'cam-3': '2023-05-15 13: 45: 21'
13 }, 'customer-186': {'cam-1': '2023-05-15 13: 30: 19', 'cam-2': '2023-05-15 13: 37: 51', 'cam-3': '2023-05-15 13: 44: 04'
14 }, 'customer-188': {'cam-1': '2023-05-15 13: 30: 40', 'cam-2': '2023-05-15 13: 38: 04', 'cam-3': '2023-05-15 13: 43: 25'
15 }, 'customer-190': {'cam-1': '2023-05-15 13: 30: 26', 'cam-2': '2023-05-15 13: 37: 00', 'cam-3': '2023-05-15 13: 43: 09'
16 }, 'customer-236': {'cam-1': '2023-05-15 13: 31: 37', 'cam-2': '2023-05-15 13: 38: 30', 'cam-3': '2023-05-15 13: 44: 41'
17 }, 'customer-249': {'cam-1': '2023-05-15 13: 31: 56', 'cam-2': '2023-05-15 13: 39: 02', 'cam-3': '2023-05-15 13: 47: 47'
18 }, 'customer-267': {'cam-1': '2023-05-15 13: 32: 27', 'cam-2': '2023-05-15 13: 45: 59', 'cam-3': '2023-05-15 13: 48: 49'
19 }, 'customer-270': {'cam-1': '2023-05-15 13: 32: 32', 'cam-2': '2023-05-15 13: 45: 57', 'cam-3': '2023-05-15 13: 53: 03'
20 }
21 ]

```

Рис. 4.7 Записи времени

Экспериментальный анализ: В общей сложности 20 человек прошли под три камерами. Из них 17 были полностью отслежены, что означает, что они были правильно идентифицированы и отслежены под трех камерами. Два человека не были полностью отслежены из-за пропущенных обнаружений, поэтому они не учитывались в полном отслеживании. Один человек был повторно распознан, но из-за недостаточной степени сходства не удалось восстановить его первоначальный ID, поэтому он также не учитывался в полном отслеживании.

Таким образом, всего 20 человек, из которых 17 были успешно полностью отслежены. Мы можем вычислить точность отслеживания системы как следующее:

$$\begin{aligned}
 \text{Точность} &= \frac{\text{число правильно отслеженных людей}}{\text{общее число людей}} \\
 &= \frac{17}{20} = 0.85
 \end{aligned}
 \tag{4.1}$$

Экспериментальный вывод: точность отслеживания нашей системы статистики трафика достигает примерно 17/20=85,0%.

ЗАКЛЮЧЕНИЕ

Работа данной статьи является применением технологий нейронной сети для оценки трафика магазина. Реализован алгоритм YOLOv5 для обнаружения посетителей. Реализован алгоритм отслеживания DeepSORT для отслеживания посетителей. Реализован алгоритм FastReID для повторно идентификации посетителей под несколькими камерами. Реализован двухстрочный метод для подсчета количества посетителей магазина. Хранения и записи изображений посетителей, характеристика и времени входа и выхода. В конце, разработала систему оценки трафика магазина на сцене супермаркета.

Основная работа данной статьи включает в себя следующие аспекты:

1. Повторная идентификация посетителя

Реализован алгоритм повторной идентификации посетителя FastReID, который используется для установления связи между идентификаторами посетителей под несколькими камерами. Модель хорошо зарекомендовала себя на наборах данных Market1501 и DukeMTMC со средней точностью (mAP) 88,4% и 81,3%.

2. Отслеживание посетителей

На основе алгоритмов YOLOv5, FastReID и DeepSORT разработан и реализован трекер посетителей, который может выполнять многоцелевое отслеживание под одной и той же камерой, а также может идентифицировать личности между камерами. Результаты тестирования на MOT16: точность отслеживания (MOTA) 66,2% и точность отслеживания (MOTP) 80,8%.

3. Применение системы подсчета посетителей в супермаркете

В данной статье разработана система оценки потоков людей на основе видеонаблюдения, которая фиксирует количество посетителей, изображения посетителей и времени, когда посетители появляются в каждой зоне супермаркета на определенном интервале времени. Точность идентификации

входящих и выходящих людей достигла 95,50%, а точность отслеживания + повторной идентификации посетителей достигла 85%.

4. Сравнения с другими продвинутыми алгоритмами на других наборах данных и выяснили преимущества и недостатки модели FastReID и модели DeepSORT.

В сценариях практического применения система отслеживания множества объектов имеет высокую точность. Но когда появится скопление народа, например 50 около входа, точность отслеживания будет снижена из-за перекрытия. Точность можно повысить, улучшив алгоритмы отслеживания объектов, например, использовать обнаружение центральной точки вместо традиционного обнаружения ограничивающей рамки, использовать облегченную структуру сверточной нейронной сети, применить технологию сегментации объектов для избежания пропущенного обнаружения и т.д.

СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ

1. Захаров Н С. ОТСЛЕЖИВАНИЕ ЛЮДЕЙ ПО ВИДЕО ПОСЛЕДОВАТЕЛЬНОСТИ[C]//Актуальные проблемы авиации и космонавтики. 2020: 135-137
2. Богуш Р П, Игнатьева С А, Абламейко С В. Сопровождение и повторная идентификация людей в интеллектуальных системах видеонаблюдения с применением сверточных нейронных сетей[J]. 2022
3. Girshick R. Fast r-cnn[C]//Proceedings of the IEEE international conference on computer vision. 2015: 1440-1448.
4. Ren S, He K, Girshick R, et al. Faster r-cnn: Towards real-time object detection with region proposal networks[J]. Advances in neural information processing systems, 2015, 28.
5. Redmon J, Divvala S, Girshick R, et al. You only look once: Unified, real-time object detection[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2016: 779-788.
6. Redmon J, Farhadi A. YOLO9000: better, faster, stronger[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2017: 7263-7271.
7. Wojke N, Bewley A, Paulus D. Simple online and realtime tracking with a deep association metric[C]//2017 IEEE international conference on image processing (ICIP). IEEE, 2017: 3645-3649.
8. Girshick R, Donahue J, Darrell T, et al. Rich feature hierarchies for accurate object detection and semantic segmentation[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2014: 580-587.
9. He K, Zhang X, Ren S, et al. Spatial pyramid pooling in deep convolutional networks for visual recognition[J]. IEEE transactions on pattern analysis and machine intelligence, 2015, 37(9): 1904-1916.

10. Ye S, Bohush R P, Chen H, et al. Person tracking and reidentification for multicamera indoor video surveillance systems[J]. Pattern Recognition and Image Analysis, 2020, 30: 827-837.
11. Dalal N, Triggs B. Histograms of oriented gradients for human detection[C]//2005 IEEE computer society conference on computer vision and pattern recognition (CVPR'05). Ieee, 2005, 1: 886-893.
12. Lowe D G. Object recognition from local scale-invariant features[C]//Proceedings of the seventh IEEE international conference on computer vision. Ieee, 1999, 2: 1150-1157.
13. Koestinger M, Hirzer M, Wohlhart P, et al. Large scale metric learning from equivalence constraints[C]//2012 IEEE conference on computer vision and pattern recognition. IEEE, 2012: 2288-2295.
14. Liao S, Hu Y, Zhu X, et al. Person re-identification by local maximal occurrence representation and metric learning[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2015: 2197-2206.
15. He K, Zhang X, Ren S, et al. Delving deep into rectifiers: Surpassing human-level performance on imagenet classification[C]//Proceedings of the IEEE international conference on computer vision. 2015: 1026-1034.
16. Lu C, Tang X. Surpassing human-level face verification performance on LFW with GaussianFace[C]//Proceedings of the AAAI conference on artificial intelligence. 2015, 29(1).
17. He L, Liao X, Liu W, et al. Fastreid: A pytorch toolbox for general instance re-identification[J]. arXiv preprint arXiv:2006.02631, 2020.
18. Wei L, Zhang S, Gao W, et al. Person transfer gan to bridge domain gap for person re-identification[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2018: 79-88.
19. Hou R, Ma B, Chang H, et al. Interaction-and-aggregation network for person re-identification[C]//Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. 2019: 9317-9326.




20. Quan R, Dong X, Wu Y, et al. Auto-reid: Searching for a part-aware convnet for person re-identification[C]//Proceedings of the IEEE/CVF International Conference on Computer Vision. 2019: 3750-3759.
21. Zhou K, Yang Y, Cavallaro A, et al. Omni-scale feature learning for person re-identification[C]//Proceedings of the IEEE/CVF international conference on computer vision. 2019: 3702-3712.
22. Chen B, Deng W, Hu J. Mixed high-order attention network for person re-identification[C]//Proceedings of the IEEE/CVF international conference on computer vision. 2019: 371-381.
23. Sun Y, Cheng C, Zhang Y, et al. Circle loss: A unified perspective of pair similarity optimization[C]//Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. 2020: 6398-6407.
24. Bewley A, Ge Z, Ott L, et al. Simple online and realtime tracking[C]//2016 IEEE international conference on image processing (ICIP). IEEE, 2016: 3464-3468.
25. Wang Z, Zheng L, Liu Y, et al. Towards real-time multi-object tracking[C]//Computer Vision–ECCV 2020: 16th European Conference, Glasgow, UK, August 23–28, 2020, Proceedings, Part XI 16. Springer International Publishing, 2020: 107-122.
26. Zheng L, Shen L, Tian L, et al. Scalable person re-identification: A benchmark[C]//Proceedings of the IEEE international conference on computer vision. 2015: 1116-1124.
27. Chen Y, Dai D, Pont-Tuset J, et al. Scale-aware alignment of hierarchical image segmentation[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2016: 364-372.
28. MOT17 Results, [Электронный ресурс]. - URL: <https://motchallenge.net/results/MOT17/> (дата обращения 26.05.23) [Электронный ресурс].
29. YOLOv5, [Электронный ресурс]. - URL: <https://github.com/ultralytics/yolov5> (дата обращения 26.05.23) [Электронный ресурс].

30. Performance Measures and a Data Set for Multi-target, Multi-camera Tracking
– Mode of access, [Электронный ресурс]. - URL:
<https://arxiv.org/abs/1609.01775> (дата обращения 26.05.23).

ПРИЛОЖЕНИЕ 1

ID	Cam-1	Cam-2	Cam-3
2			
5			
8			-
21			
25			

34			
43			
58			
61		-	
77		-	
183			

186			
344			
190			
236			
249	 1		
267	